

```

• begin
•     using HiGHS
•     using JuMP, BenchmarkTools
•     using Plots, LinearAlgebra, Distributions, Random
• end

```

Considere uma rede 2D com  $n$  nós beacon em posições conhecidas  $x_i \in \mathbb{R}^2, i = 1, \dots, n$

Assumimos uma coordenada  $x^k = (x, y)$  como uma posição desconhecida inicial

O nó alvo  $x^k$  vai transmitir um sinal no instante  $t_0$  e os nós beacon irão receber o sinal no instante  $t_i$  conforme a expressão abaixo

$$t_i = t_0 + \frac{d_i}{v} + \omega_i$$

```

• md"
• $t_i = t_0 + \frac{d_i}{v} + \omega_i$
• "

```

em que  $d_i = \sqrt{(x_i - x)^2 + (y_i - y)^2}$  conforme a distancia euclidiana entre o beacon  $i$  e o ponto  $x$ , sendo  $v$  a velocidade de propagação do sinal

$$\omega_i \approx n(0, \frac{\sigma_i^2}{v^2})$$

Supondo que  $t_0$  é um parâmetro desconhecido fixo durante o processo. Para evitar a influência deste parâmetro, subtraímos todas as medições  $t_i$  da última medição. Consequentemente, pode ser expresso como

$$t_i - t_n = (t_0 + \frac{d_i}{v} + \omega_i) - (t_0 + \frac{d_n}{v} + \omega_n)$$

$$t_i - t_n = \frac{d_i - d_n}{v} + \omega_i - \omega_n$$

$$v(t_i - t_n) = d_i - d_n + v(\omega_i - \omega_n)$$

incluindo variaveis para cada parte da equação

$$r_i = v(t_i - t_n)$$

$$d_{i,n} = d_i + d_n$$

$$X_i = v(\omega_i - \omega_n)$$

obtivemos a seguinte expressão

$$R = D + X$$

sendo  $R$  a distância entre os pontos fixos e o ponto alvo ( $x_k$ ) considerando os erros, obtemos

$$R = [r_1, r_2, \dots, r_n]$$

$$D = [d_{1,n}, \dots, d_{n-1,n}]$$

$$X = [X_1, \dots, X_{n-1}]$$

consideramos a minimização da norma  $\ell_1$  abaixo

$$\underset{x}{\text{minimize}} \|R - D\|_1$$

```
• md"  
•  $\underset{x}{\text{minimize}} \left\| R - D \right\|_1$   
• "
```

A norma  $\ell_1$  é um problema de otimização não convexo e difícil de resolver, se propõe uma solução eficiente com um método subótimo para resolver este problema. Descrevemos o procedimento de aproximação da norma  $\ell_1$  com minimização de resíduos em um problema de otimização convexo, usando um vetor fictício  $s$ .

$$s = [s_1, \dots, s_{n-1}]^T$$

$$\underset{x,s}{\text{minimize}} \sum_{i=1}^{n-1} s_i$$

sujeito a  $s_i = r_i + \|x - x_n\|_2 - \|x - x_i\|_2$

O problema em questão é não convexo e não linear. No caso de relações sinal-ruído suficientemente altas, a restrição acima pode ser aproximado usando a expansão em série de Taylor de primeira ordem, de modo que podemos estudar como a função  $f$  se comporta em torno de um ponto fixo  $\mathbf{x}^k$

$$\begin{aligned} \min \quad & \sum_{i=1}^{n-1} s_i \\ \text{s. a.} \quad & A_i \mathbf{x} + C_i - s_i = 0 \end{aligned}$$

conforme a expansão de taylor de primeira ordem:

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \frac{f'(\mathbf{x}_0)}{1!}(\mathbf{x} - \mathbf{x}_0)$$

Sendo assim temos  $s_i(\mathbf{x}_k) = r_i + \|\mathbf{x}_k - \mathbf{x}_n\|_2 - \|\mathbf{x}_k - \mathbf{x}_i\|_2$

$$s_i(\mathbf{x}_k)' = \frac{\mathbf{x}_k - \mathbf{x}_n}{\|\mathbf{x}_k - \mathbf{x}_n\|_2} - \frac{\mathbf{x}_k - \mathbf{x}_i}{\|\mathbf{x}_k - \mathbf{x}_i\|_2}$$

substituindo na expansão de taylor:

$$f(\mathbf{x}) = r_i + \|\mathbf{x}_k - \mathbf{x}_n\|_2 - \|\mathbf{x}_k - \mathbf{x}_i\|_2 + \left( \frac{\mathbf{x}_k - \mathbf{x}_n}{\|\mathbf{x}_k - \mathbf{x}_n\|_2} - \frac{\mathbf{x}_k - \mathbf{x}_i}{\|\mathbf{x}_k - \mathbf{x}_i\|_2} \right)(\mathbf{x} - \mathbf{x}_k)$$

$$f(\mathbf{x}) = r_i + \|\mathbf{x}_k - \mathbf{x}_n\|_2 - \|\mathbf{x}_k - \mathbf{x}_i\|_2 + \mathbf{x} \frac{\mathbf{x}_k - \mathbf{x}_n}{\|\mathbf{x}_k - \mathbf{x}_n\|_2} - \mathbf{x} \frac{\mathbf{x}_k - \mathbf{x}_i}{\|\mathbf{x}_k - \mathbf{x}_i\|_2}$$

$$- \mathbf{x}_k \frac{\mathbf{x}_k - \mathbf{x}_n}{\|\mathbf{x}_k - \mathbf{x}_n\|_2} + \mathbf{x}_k \frac{\mathbf{x}_k - \mathbf{x}_i}{\|\mathbf{x}_k - \mathbf{x}_i\|_2}$$

incluindo variaveis para cada parte da equação

$$A_i = \left( \frac{\mathbf{x}_k - \mathbf{x}_n}{\|\mathbf{x}_k - \mathbf{x}_n\|_2} - \frac{\mathbf{x}_k - \mathbf{x}_i}{\|\mathbf{x}_k - \mathbf{x}_i\|_2} \right)$$

$$C_i = r_i + \|\mathbf{x}_k - \mathbf{x}_n\|_2 - \|\mathbf{x}_k - \mathbf{x}_i\|_2 - \mathbf{x}_k \frac{\mathbf{x}_k - \mathbf{x}_n}{\|\mathbf{x}_k - \mathbf{x}_n\|_2} + \mathbf{x}_k \frac{\mathbf{x}_k - \mathbf{x}_i}{\|\mathbf{x}_k - \mathbf{x}_i\|_2}$$

Relaxando a minimização anterior obtivemos:

$$A_i x + C_i - S_i \leq 0$$

calcula\_r\_i (generic function with 1 method)

```

• function calcula_r_i(n,σ,x_k,X,v)
•     ω = similar(σ)
•     for (index,σi) in enumerate(σ)
•         ω[index] = rand(Normal(0,σi/v))
•     end
•     ω_n = pop!(ω)
•     ω .-= ω_n
•     ω *= v
•     D = ((norm.(X .- [x_k]))[1:end-1].-(norm.(X .- [x_k]))[end])
•     R = D + ω
•     return R
• end

```

solucao\_LP (generic function with 1 method)

```

• function solucao_LP(A, C, n)
•     IC = Model(HiGHS.Optimizer)
•     @variable(IC,x[1:2]>=0)
•     @variable(IC,s_i[1:n-1]>=0)
•     @objective(IC, Min,sum(s_i))
•     @constraint(IC,(A*x)+C-s_i .== 0)
•     print(IC)
•     optimize!(IC)
•     println("Termination status: $(termination_status(IC))")
•     if termination_status(IC) == MOI.OPTIMAL
•         println("Optimal objective value: $(objective_value(IC))")
•         println("x: ",value.(x))
•     else
•         @constraint(IC,(A*x)+C-s_i .<= 0)
•         print(IC)
•         optimize!(IC)
•         println("Termination status: $(termination_status(IC))")
•         if termination_status(IC) == MOI.OPTIMAL
•             println("Optimal objective value: $(objective_value(IC))")
•             println("x: ",value.(x))
•             println("s: ",value.(s_i))
•         else
•             println("No optimal solution available")
•         end
•     end
• end
• end

```

```
• let
• function Input(prompt)
•     print(prompt)
•     readline()
• end
•
• n = Input("valores de X, digitar [[12.,12],[12.,12]]\n")
• println("Your name is $n.")
• end
```

```
valores de X, digitar [[12.,12],[12.,12]] ⓘ
Your name is .
```

```

• let
•
• #####MAIN#####
• Random.seed!(10)
• X = [[0.,0],[100,100.],[0,100.],[100,0.]]
• n = length(X)
• x_k = [111,99]
• v = 20
• σ = Float64[.5,2,2.0,1]
• R = calcula_r_i(n,σ,x_k,X,v)
• A_i(x_i) = ((x_k - X[end])/norm(x_k - X[end])) - ((x_k - x_i)/norm(x_k - x_i))
• C_i(x_i) = norm(x_k - X[end]) - norm(x_k - x_i) + dot(A_i(x_i),-x_k)
• C = R + C_i.(X[1:end-1])
• A = A_i.(X[1:end-1])
• A = permutedims(hcat(A...))
• solucao_LP(A,C,n)
•
• end

```

Min  $s_i[1] + s_i[2] + s_i[3]$  ②  
 Subject to  
 $-0.6358639083936645 \ x[1] + 0.32826888771521723 \ x[2] - s_i[1] = -38.480839190$   
 $290226$   
 $-0.8854616803928573 \ x[1] + 1.0844194807161374 \ x[2] - s_i[2] = 8.951405820934$   
 $113$   
 $-0.8895278952735653 \ x[1] + 1.00289237810919 \ x[2] - s_i[3] = -0.6220942608272$   
 $448$   
 $x[1] \geq 0.0$   
 $x[2] \geq 0.0$   
 $s_i[1] \geq 0.0$   
 $s_i[2] \geq 0.0$   
 $s_i[3] \geq 0.0$   
 Running HiGHS 1.3.0 [date: 1970-01-01, git hash: e5004072b-dirty]  
 Copyright (c) 2022 ERGO-Code under MIT licence terms  
 Presolving model  
 3 rows, 5 cols, 9 nonzeros  
 2 rows, 4 cols, 6 nonzeros  
 2 rows, 4 cols, 6 nonzeros  
 Presolve : Reductions: rows 2(-1); columns 4(-1); elements 6(-3)  
 Solving the presolved LP  
 Using EKK dual simplex solver - serial  

Iteration	Objective	Infeasibilities	num(sum)
0	0.000000000000e+00	Pr: 2(253.011)	0s
2	9.9040873089e-01	Pr: 0(0)	0s

 Solving the original LP from the solution after postsolve  
 Model status : Optimal  
 Simplex iterations: 2  
 Objective value : 9.9040873089e-01  
 HiGHS run time : 0.00  
 Termination status: OPTIMAL  
 Optimal objective value: 0.9904087308934351  
 x: [111.98492400616007, 99.6936764163446]

• [##http://www.cnmac.org.br/novo/index.php/CNMAC/conteudo/2022/53/99](http://www.cnmac.org.br/novo/index.php/CNMAC/conteudo/2022/53/99)

